

**Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО**

Факультет безопасности информационных технологий

Дисциплина:

«Теория информации»

ОТЧЕТ ПО ЛАБОРАТОРНОЙ РАБОТЕ №2

«Словарные алгоритмы»

Выполнил:

Трушкина Анна Владимировна, студент группы N3245

Санкт-Петербург
2026 г.

Цель работы:

Изучение и программная реализация словарных алгоритмов сжатия данных LZ77, LZ78 и LZW. Анализ их эффективности, расчёт степени сжатия с учётом overhead словаря, сравнение скорости работы и зависимости от характера данных.

Краткое описание алгоритмов

LZ77 использует скользящее окно и буфер просмотра. Алгоритм ищет в уже обработанной части текста (окне) совпадения с текущей позицией и заменяет повторяющиеся последовательности парами (смещение, длина). Словарь не хранится явно – это само окно, поэтому overhead минимален.

LZ78 строит динамический словарь, начиная с пустого. Алгоритм добавляет в словарь новые подстроки по мере их появления и заменяет их парами (индекс в словаре, следующий символ). Словарь необходимо передавать вместе со сжатыми данными для распаковки.

LZW – усовершенствованная версия LZ78. Словарь инициализируется всеми символами алфавита (256 записей для ASCII), что позволяет кодировать только индексы без символов. Словарь динамически расширяется в процессе сжатия.

Результаты тестирования:

Параметры реализации:

- LZ77: размер окна = 4096, размер буфера = 16, токен = 24 бита (12 бит смещение + 4 бита длина + 8 бит символ)
- LZ78: токен = 20 бит (12 бит индекс + 8 бит символ), overhead словаря = 20 бит на запись
- LZW: код = 12 бит, overhead словаря = 2048 бит (начальная инициализация 256 записей)

Таблица 1. Результаты для строки "abracadabra" (короткий текст)

Алгоритм	Токенов	Размер (бит)	Overhead словаря (бит)	Степень сжатия	Время (мс)
LZ77	8	192	0	2.1818	0.02
LZ78	7	280	140	3.1818	0.01
LZW	9	2156	2048	24.5000	0.02

Таблица 2. Результаты для строки "а" × 100 (повторяющийся текст)

Алгоритм	Токенов	Размер (бит)	Overhead словаря (бит)	Степень сжатия	Время (мс)
LZ77	8	192	0	0.2400	0.32
LZ78	14	540	260	0.6750	0.02
LZW	14	2216	2048	2.7700	0.03

Таблица 3. Результаты для строки "abcdef123456" (уникальные символы)

Алгоритм	Токенов	Размер (бит)	Overhead словаря(бит)	Степень сжатия	Время(мс)
LZ77	12	288	0	3.0000	0.01
LZ78	12	480	240	5.0000	0.00
LZW	12	2192	2048	22.8333	0.02

Сравнение алгоритмов:

Степень сжатия:

- LZ77 показывает лучшую степень сжатия во всех тестах благодаря отсутствию overhead словаря.
- LZ78 занимает промежуточное положение.
- LZW имеет наибольший overhead из-за начальной инициализации словаря (2048 бит), что делает его неэффективным для коротких строк.

Скорость работы:

- Все алгоритмы работают очень быстро (доли миллисекунды).
- LZ77 немного медленнее на повторяющихся данных из-за поиска совпадений в окне.

Зависимость от характера данных:

- На повторяющихся данных все алгоритмы показывают хорошую степень сжатия (< 1.0).
- На уникальных символах сжатие отсутствует (степень > 1.0).

Сложность реализации:

- LZ77: средняя сложность (поиск совпадений в окне).
- LZ78: простая реализация (словарь на хеш-таблице).
- LZW: простая реализация, но требует начальной инициализации словаря.

Примеры преимущества одного алгоритма над другим:

Пример, где LZ77 выигрывает у обоих:

Все три тестовых строки показывают, что LZ77 даёт лучшую степень сжатия. Например, для "abracadabra": LZ77 = 192 бит, LZ78 = 280 бит, LZW = 2156 бит. Причина: отсутствие overhead словаря у LZ77.

Пример, где LZW сжимает лучше LZ78:

Для длинных текстов с повторяющимися паттернами LZW становится эффективнее LZ78, так как начальная инициализация словаря (2048 бит) окупается за счёт более компактного кодирования (12 бит на код против 20 бит на токен у LZ78). В наших тестах на коротких строках LZW проигрывает из-за большого фиксированного overhead.

Вывод

В ходе работы были реализованы три словарных алгоритма сжатия. LZ77 показал наилучшие результаты на коротких строках благодаря отсутствию overhead словаря. LZ78 и LZW требуют передачи словаря для распаковки, что увеличивает общий размер сжатых данных. LZW эффективен на длинных текстах, где начальная инициализация словаря окупается. Выбор алгоритма зависит от характера данных и требований к памяти.